202-2-5211 עיבוד שפה טבעית

ד״ר יובל פינטר סמסטר א' תשפ"ד

לפני הכל

- המרחב המוגן הוא בחדר 328 ("צמוד לגרם מדרגות צפוני") -
 - <u>psychserv@bgu.ac.il</u>, 08-6461088 מוקדי סיוע נפשי
- אחראים מחלקתיים לנושאי מילואימניקים: פרופ' גרא וייס, פרופ' אריה קנטרוביץ', גב' זהבה קובני, גב' בת אל אמר גולדשטיין
 - מתנדב.ת לקשר עם הכיתה?

אמ;לק הקורס

- ▶ אנחנו רוצים לגרום למחשבים להתמודד עם▶ האתגרים של שפה אנושית
 - נלמד מהם האתגרים
 - נלמד כמה אופיי התמודדות
- נלמד איך לדעת אם הצלחנו, ואיך נראה העולם שלנו בעקבות ההצלחות



קצת עליי

- רקע בלשני ומדמ״חי ●
- תחומי מחקר עיקריים בתוך נל״פ: ●
- קומפוזיציונליות לקסיקלית: האם ואיך הבפנוכו של המילים בונה את המשמעות שלהן
 - **פרטיות**: איך אפשר לתשאל מודלי שפה גדולים בלי להסגיר פרטים חסויים
 - "למה המודל עשה את מה שהוא עשה" סברנות: "למה המודל עשה את מה שהוא עשה"

- לשון פניה: אתה/הוא
- עמדתי על מגדר: אני משתדל להתנסח בגוף שני/שלישי בלשון כוללנית (inclusive) אתןם, אנשיםות,
 סטודנט.ית. בדיבור קצת יותר קשה לי, אשמח להערות.

מנהלות

- כתובתי: uvp@cs.bgu.ac.il •
- שעות קבלה: רביעי 12:00-14:00 (לפני השיעור), אלון (37) חדר 203;
 ראשון זמין באופן כללי בזום, 9:00-11:00 תמיד, מומלץ ליצור קשר קודם;
 מי שלא יכול.ה בשעות האלה, ליצור איתי קשר ונקבע ספציפית.

נא לפנות בנימוס

- הכלל השמרני, בגדול, באקדמיה: פניה ראשונה למי שלא מכיריםות בתואר ושם משפחה. במידה ונעניתןם בחתימה עם שם פרטי ניתן לאחר מכן לפנות בשם פרטי]
 - בע"פ "יובל" זה בסדר. שמי האמצעי מתעקש להופיע בכל מיני מערכות אך אני לא משתמש בו.
- רשתות חברתיות עקבו אחריי לשיקולכםן (ציוציי אינם מייצגים וכו' וכו'); אני לא אעקוב חזרה כל עוד הקורס מתקיים; נא לא לפנות בהודעה פרטית ברשתות.

נוכחות

אין חובת נוכחות מלבד בהרצאת האורח, אבל הולכות להיות לכןם שאלות ולכן מומלץ מאוד להגיע.
 בהתאם למתווה השנה ההרצאות היברידיות ומוקלטות אבל עד כמה שניתן נא להגיע פיזית.

מנהלות (המשך)

- שאלות במהלך ההרצאה
- כמה שיותר, אבל נסו בנקודות שמתאימות לכך ○

פורום •

- כרגע יש במודל
- פתוח להצעות

• משובים

- יהיו רשמיים
- מבקש לפנות אליי בכל עת משובים זריזים על שיטות הוראה יכולים לטופל במהרה 🌣
 - ∨ אפשר באנונימיות ליצור כתובת מייל / פתק פיזי (בנין 37 קומה 1, תיבה 23)

קצת עליכםן

https://app.wooclap.com/SSJSPM



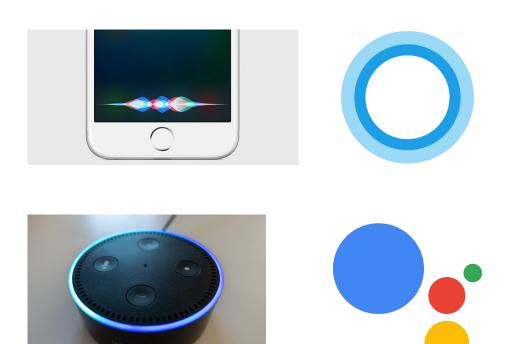
(שאלות 1-8)

אמ;לק עיבוד שפה

- תחום יישומי ●
- בעיות שמגיעות מ**חקר השפה** או מיישומי קצה
 - פתרונות שמגיעים (לרוב) מלימוד מכונה
 - חוסה תחת מטריית בינה מלאכותית

(שאלה 9)

"תחום יישומי"





"תחום יישומי"





You

מה אפשר ללמוד בקורס עיבוד שפה טבעית באוניברסיטת בן גוריון?



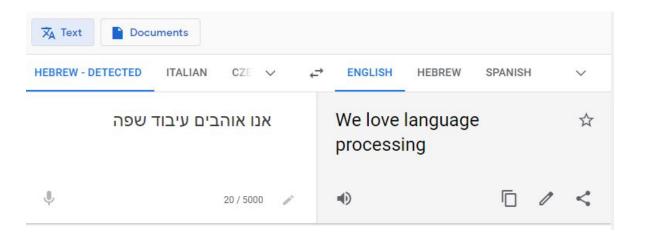


ChatGPT

לפי המידע הזמין לי עד לספטמבר 2021, אוניברסיטת בן-גוריון בנגב בישראל מציעה מספר קורסים בתחום עיבוד שפה טבעית במסגרת תוכנית הלימודים שלה. הנה כמה דוגמאות לקורסים שמתמקדים בתחום עיבוד שפה טבעית:

- עיבוד שפה טבעית (Natural Language Processing): קורס זה מתמקד בשיטות ובטכניקות באמצעות מחשבים. הקורס מתמקד בנושאים כמו דקדוק לעיבוד, ניתוח והבנת שפה טבעית, מודלים חישוביים לעיבוד שפה, ויישומים שונים של עיבוד וסמנטיקה של השפה הטבעית, מודלים חישוביים לעיבוד שפה, ויישומים שונים של עיבוד.
- יישוםים של עיבוד שפה טבעית: קורס זה עוסק ביישומים מעשיים של עיבוד שפה טבעית.
 בתחומים רחבים כמו חיזוי טקסט, שימושים בסוגיות של חיפוש מידע, תגובות אוטומטיות.
 למשתמש, ויישומים נוספים בתחום האינטרנט והמחשוב.
- עיבוד שפה טבעית מתקדם: קורס מתקדם זה עוסק בתכנות מתקדם וטכניקות יישום בעיבוד
 שפה טבעית. הקורס עשוי לכלול

עוד דוגמא



חקר שפה (בלשנות)

- מהן אבני הבניין היסודיות של שפה?
- ?איך מרכיבים אותן לתיאור מצבים ולביטוי רעיונות מסובכים ו/או מקוריים
 - אילו שיטות נוקטות שפות שונות לבטא פנים שונות בעולם?
 - השפה כתופעה **חברתית**
 - איך החברה משפיעה על השפה? ○
 - ? איך שפה משתלבת באמצעי תקשורת אחרים ○

לימוד מכונה

- איך מזהים **תבניות** בנתונים? \bullet
- עד כמה ניתן ללמוד מ**דוגמאות?** ●
- (train vs. test) דאטא אימון מול דאטא מבחן \circ
 - למידה תחת מגבלות שונות:
 - נתונים מעוטים
 - כוח חישוב מועט
 - יזמן-אמת ○
 - "למידה עמוקה" ●

ספוילר: הרבה אלגברה לינארית, הרבה הסתברות, פה ושם חדו"א מרובת-משתנים

בינה מלאכותית

- איך בונים מכונות שיודעות לעשות דברים שבני אדם עושים?
- אילו מערכות יכולות לעזור לבני אדם בהתנהלות היומיומית?
- ? מהי ההשפעה של פרישת מערכות כאלה על העולם והחברה
 - הטיה ○
 - כ נגישות ○
 - ס פרטיות \circ

תחומים שכנים / משיקים

- עיבוד שפה טבעית עוסק, בכללותו, ב**טקסט**
- (Speech) זיהוי וייצור קול נכנס תחת תחום **דיבור**
 - זיהוי קול אוטומטי ASR ∘
 - יטקסט לדיבור וההיפך TTS, STT ∘
- למה זה בנפרד? "סיבות היסטוריות" (מדמ"ח מול הנדסה)
- שפות סימנים לצערנו אין הרבה, מה שקיים לרוב נכנס ב-NLP
- שם נרדף לנל״פ, הרבה פחות בשימוש (HLT) שם נרדף לנל״פ, הרבה פחות בשימוש
 - בלשנות חישובית ייכלל חלקית בקורס
- פסיכובלשנות איך **אנחנו** מעבדים שפה? (קשר הדוק למדעי המוח וקוגניציה)
 - סוציובלשנות איך אנחנו, כחברה, **משתמשים** בשפה?
 - (data science) מדעי המידע
 - (data mining / text mining) כריית מידע/טקסט

...

עצירה לשאלות

דוגמאות לשאלות מרכזיות בעיבוד שפה

- בהינתן מסמך (נניח ביקורת על ספר), האם היחס שלו למושא הכתיבה חיובי או שלילי?
 - בהינתן משפט, מהו ה**פועל** העיקרי שלו?
 - בהינתן טקסט, אילו ישויות מופיעות בו?
 - בהינתן כינוי גוף בטקסט (pronoun), לאיזו ישות הוא מתיחס?
- בהינתן צורת מקור של מילה ותכוניות התאם (גוף, זמן), מהי הצורה ה**נטויה** המתאימה?

דוגמאות לשאלות הרבה פחות מרכזיות בעיבוד שפה

- ?איך מזהים מבע סרקסטי
- ?איך אפשר לפרק הלחמים (blends)? איך נוצרים הלחמים
 - איך פותרים הגדרה בתשבץ הגיון?
 - ?איך משחזרים סימנים דיאקריטיים בטקסט איטלקי
- ?האם אפשר לחזות אילו מילים שהאקדמיה ללשון מציעה ייקלטו בשפה

שאלות מרכזיות, שאלות לא מרכזיות

העיקר להגדיר את הבעיה נכון

אתגרים בעיבוד שפה

- ייש לי רעיון״ ⇔ ״ו brangoe ama indae,aara
 - משתחתבין גתבוומי תוכן (domains)
 - ועוד **רמישואי א'זמיו**, דמיק די ועוד •
- יזרעגעשילע ולאַוולםנס בתיק כי הוא [גדול/קטן] מדי.״
 - דכב שהשתוות התימה דאטא

עוד אתגרים בעיבוד שפה

- דו-משמעות ●
- (נדון בהרחבה)
 - מילים לא-מוכרות •

 $Pr(w_n) \propto rac{1}{n^s}$,שבור המילה ה-n בשכיחותה, (Zipfian) התפלגות מילים בגוף טקסט גדול היא **זיפפיאנית** \circ

- קומפוזיציונאליות והעדרה •
- \circ דיבר+ת = דיברת; למד+ת = למדת; ברק+ת = ברקת?
 - ספר ⇔ בית-ספר ○
 - ?!אכל את הראש = אכל את הראש?!?

עיבוד שפה והחברה

יש יישומים של עיבוד שפה בעלי השלכות משמעותיות על החיים •

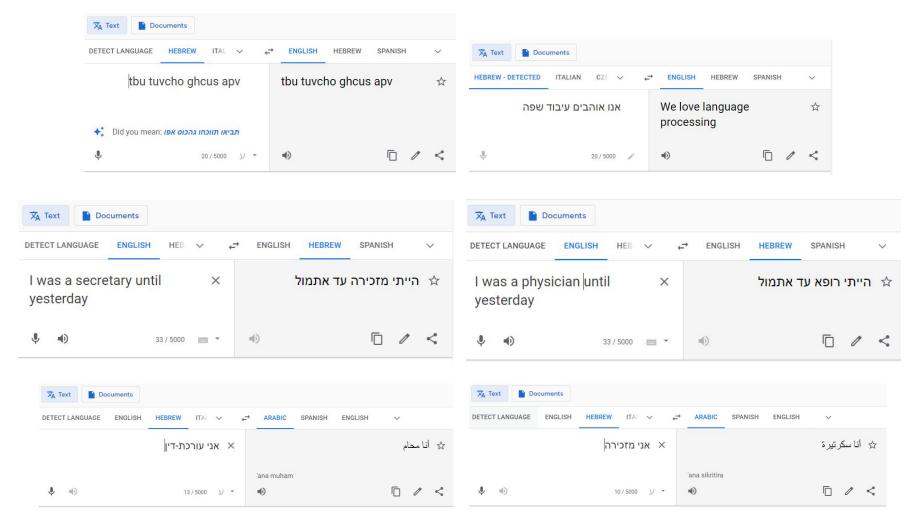
- פיננסים
- משפטים כ
 - רפואה •

איך דואגים שהמערכות בשימוש יהיו הוגנות?

איך מגדירים מערכת "הוגנת"? □

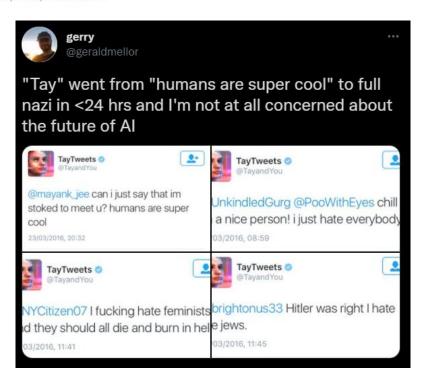
?האם ואיך אפשר להסביר למשתמש-קצה למה המערכת החליטה מה שהחליטה

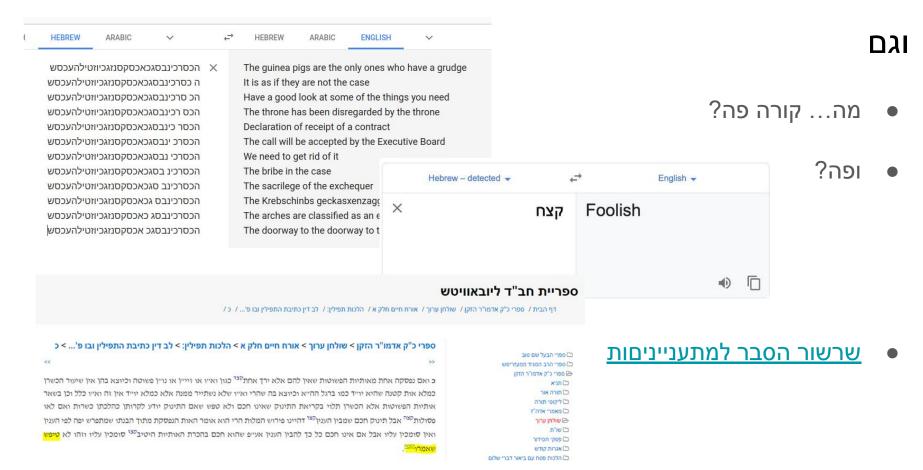
- ?עד לפני 8-7 שנים
 - ?ומאז



Twitter taught Microsoft's AI chatbot to be a racist asshole in less than a day

By James Vincent | Mar 24, 2016, 6:43am EDT





מונחי יסוד בעיבוד שפה

- על משימה T בהינתן (metric): שיטת מדידה שקובעת את ביצועיה של מערכת (metric) אינתן בהער דאטא D דאטא
 - למשל: אחוזי דיוק
 - חיוני כחלק מהגדרת הבעיה 🔾
 - ▶ קורפוס (corpus): אוסף מסמכים בשפה (או שפות) שמשמש לניתוח לשוני או סטטיסטי
 ולאימון בלתי-מבוקר (unsupervised)
 - ס למשל: אוסף כל הויקיפדיות של שפות עם למעלה מ-100,000 ערכים ○
 - (annotation, labeling, tagging): אוסף מסמכים ותגיות (task data): אוסף מסמכים ותגיות (semi-supervised) שמשמש ללימוד משימה מבוקר (supervised) או חצי-מבוקר
 - י שהוענקו האיונים שהוענקו מ-dMDb בשילוב הציונים שהוענקו ∘
 - סומנות בהם שכל הישויות (שמות אנשים, שמות מקומות, שמות ארגונים) מסומנות בהם 🔾

עיבוד שפה - הנגדות

- (NLU vs. NLG) ״הבנה״ מול ״יצירה״ •
- (document-level vs. sequence tagging) ״מסמכים״ מול ״אטומים״
 - ״רצפים״ מול ״שק מילים״ ●
- (inductive bias) ארכיטקטורות גנריות מול ארכיטקטורות עם ידע מוטמע ●

Who is wearing glasses? woman man

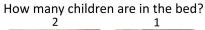








Is the umbrella upside down?



Where is the child sitting?





"Rinse off a mug and place it in the coffee maker"



עיבוד שפה ועוד

- (multimodal) מולטימודאליות
 - (grounding) קרקוע
- תחומים שהתקדמו מאוד מאז שיש למידה עמוקה (?מה?) ס

(language modeling) מידול שפה

- משימה קלה להגדרה, בעלת שם מבלבל ומידת יישומיות חמקמקה
 - הגדרה קלאסית: **בהינתן רצף מילים, מהי המילה הבאה?**
- עם ח מילים (ונניח סימן מיוחד לתחילת המסמך כ- (w_0^-) :

$$Pr(D) = \prod_{i \in I} Pr(w_i | w_0, \dots, w_{i-1})$$

עצירה לשאלות

מבנה הקורס

- עיבוד שפה הוא תחום של **בעיות**
- ◆ לפני שניגשים לפתור בעיה צריך להגדיר אותה
 - לכן רוב היחידות (~שבוע) יכללו:
- חצי הרצאה עד הרצאה של הגדרת הבעיה (לשונית) ואיך נמדוד פתרון ○
- שיטה מרכזית מתחום למידת המכונה (ML) ויישומה על הבעיה שהוצגה 🤄
- (לפעמים גם שיטה "פשוטה" יותר, לפעמים מספר שיטות, לפעמים עוד בעיות עם אותה שיטה)
 - יחידות נוספות: ●
 - מאתברד טקסט בסיסי 🔾
 - देखात्र प्रचेता (हार क्राव्य हार्ग)
 - ס ושבחתבת (10√1-19∞דלי שפה גדולים ○
 - השלכות של עיבוד שפה (ובינה מלאכותית ככלל) על החברה האנושית בייבור אפרי אוביר אפרי
 - יישומים **של** עיבוד שפה בתחומים קשורים (מי ה״לקוחות״ שלנו) 🌼
 - לו"ז מפורט ברמת השיעור, לרבות שינויים במוד ההוראה, נמצא במודל

תרגיל	בוחן	SLP	תוכן	יחידה	תאריך	
			מבוא לנל"פ		2/1/24	
0 (ללא ציון)		2	עיבוד טקסט	מבואות	3/1	
			סנטימנט	0122000 20110	9/1	
יוצא 1	1	4	בייז התם + רגרסיה לוגיסטית	סיווג מסמכים	10/1	
			חלקי דיבר וישויות		16/1	
	2	4-5	מרקוב, ויטרבי	תיוג רצפים	17/1	
1 מוגש		8	רשתות נוירונים	D 22 1 X1 31	23/1	
יוצא 2	3	8	תיוג רצפים נוירוני		24/1	
		7	תחביר	ניתוח תחבירי	30/1	
	4	9	אלגוריתמי ניתוח תחבירי		31/1	
1 חוזר, 2 מוגש		17-18	השלמות	חזרה ועיבוי	6/2	
3 יוצא		18	חזרה		7/2	
		23	סמנטיקה לקסיקלית, דמיון מילים	שיכונים	13/2	
	5	6	סקיפגראם, שימושים קלאסיים	(Embeddings)	14/2	
2 חוזר, 3 מוגש		(21)	תרגום מכונה, סיכום טקסט	חילול	20/2	בחירות?
4 יוצא	6		רובוטריקים (Transformers)		21/2	:31111111
		13	טכניקות אימון מתקדמות	רובוטריקים	27/2	
5 יוצא	7	10-11	דגימה והנחיה	ו ובוטו יקים מתקדם	28/2	
3 חוזר, 4 מוגש			מולטימודאליות	100	5/3	
	8		הרצאת אורח (הבנת שפה טבעית)	יישומי	6/3	
			חברה + אתיקה	010	12/3	
4 חוזר, 5 מוגש	9		חזרה		13/3	
17 חוזר					17/3	
				מועד א	29/3	
				מועד ב	10/4	
				מועד ג	???	

חומר

- ספרי לימוד עיקריים: ●
- Dan Jurafsky & James H. Martin: Speech and Language Processing (3rd edition)
 - <u>זמין חינם לחלוטין ברשת,</u> פרקים מתעדכנים, גרסאות קודמות זמינות
- Jacob Eisenstein: Natural Language Processing.
- יש ספר מודפס, אנחנו נשתמש ב<u>גרסת הטיוטה הזמינה ברשת</u> (ובמודל) מתאריך 13/11/2018
 - ספרי פרקים בראש כל חלק במודל (ובשקף הבא) לא בהכרח חד-חד ועל ○
 - חומר נוסף יינתן לעתים פר נושא (סרטונים, טוטוריאלים, מאמרים)
 - עדיין, חשוב לעקוב אחרי השיעורים. ●

יחידות מרכזיות (שבועות ~2-8

	גישות לפתרון	בעיה אלגוריתמית	תופעה לשונית
(SLP 4	רגרסיה לוגיסטית (LR), בייז נאיבי (NB), פרספטרון (perceptron)	(classification) סיווג	אפיון מסמכים (documents)
(SLP 7	מודל מרקוב סמוי (HMM), רשת נוירונים נשנית (Recurrent NN)	(sequence tagging) תיוג רצפים	תכונות מילים (word classes)
(SLP 12-1	תכנות דינמי לעצים (CKY), 4, E 10-11) (shift-reduce) הזחה-צמצום	ניתוח תחבירי (parsing)	תחביר (syntax)
(SLP 6;	שיכון מילים התפלגותי (distributional word embeddings)	(word similarity) דמיון מילים	סמנטיקה לקסיקלית (lexical semantics)
(SLP 10, E	(encoder-decoder), מודולי צומי (attention), מודולי צומי (LLMs = BERT, GPT),	(text generation) חילול טקסט	תרגום (MT) / תמצות טקסט (summarization)

יחידות ש**לא** יילמדו השנה ואפשר להשלים עצמאית

ה אלגוריו	ז אלגוריתמית	תופעה לשונית ב
•	ז תפקידים סמנטיים (SRL); ה (inference)	•
	personal) נים אישיים (chatbots), בוטי-שיח (assista	

שפת הוראה

- עיבוד שפה טבעית הוא תחום מחקר אנגלוצנטרי באקסטרים●
 - עם זאת, אנחנו בישראל ורובנו דובריםות עברית כשפת אם
 - כל עוד קל ונוח להסביר עם **דוגמאות** בעברית, כך אעשה •
- כאשר לא נדרש ידע בשפה, יהיו דוגמאות משפות שאינן עברית או אנגלית
 - בכל יתר המקרים, הדוגמאות יהיו באנגלית (וכך גם בספרי הלימוד)
- המונחים בתחום, כמו ברוב המדע, מוכרים בשמם האנגלי. אשתדל להשתמש בתרגומם לעברית (לפעמים מקורי שלי) אבל תמיד אתן גם את גרסת המקור.

להתפלגות כישורי האנגלית יש תומך רחב, ולכן:

Know what you don't know

למה לצפות מהקורס

- ?האם אבין יותר מהי שפה אנושית
 - C|.
- האם אדע להגדיר בעיות הנוגעות להבנה של שפה, ולגשת לפתרונן?כו.
 - ?האם אדע **לפתח** מודל שפה גדול
 - כנראה שלא. ○
 - ?האם אדע **לעבוד** עם מודל שפה גדול
 - כנראה שכן.
 - האם אדע לעבוד בלי מודל שפה גדול?
 - C|.

דרישות הקורס

- (מועד א' **29/3**, מועד ב' **10/4**, מועד ג' טרם נקבע 30% מהציון (מועד א' **29/3**, מועד ב' 10/4, מועד ג' טרם נקבע •
- אין חובה לעבור כדי לעבור את הקורס הציון המשוקלל הוא הקובע; ציון מעבר (תואר מתקדם) הינו 65.
 - חמישה תרגילי בית 40%
 - לרוב כל שבועיים
 - כמעט שבועיים להגשה
 - לפחות שניים יכללו מרכיב תכנותי
 - היה אמור להיות בודק, נאחל לשובו בשלום ובבטחה מהמילואים
 - 8% מיני-בחנים שבועיים
 - לא בזמן השיעור
 - לפחות 96 שעות להגשה, ולרוב מרביעי עד שלישי 🤉
 - ללא חומר עזר אבל יש שני נסיונות (שביניהם מותר לחזור על חומר)
 - \circ הבוחן בעל הציון הנמוך לא ייחשב (ובוחן \circ ללא ציון)
 - נוכחות בהרצאת אורח.ת 2%
 - **6/3/24** רשמו ביומנים
 - י ניתן להמיר בציון המיני-בוחן הנותר ○

מילואים והקלות

- הסיבה המרכזית שיש יותר תרגילים השנה (והם קצרים יותר) היא לאפשר גמישות למילואימניקיםות לקבל פטור מהגשה של חלק, וזה יהיה מוד ההקלות העיקרי. מרכיב התרגילים ייקבע על-סמך הציונים בתרגילים שיוגשו.
- מועדי ההגשה המתוכננים כרגע הם: 23/1, 20/2, 6/2, 20/2, 5/3, 13/3. נסו לכוון מוקדם ככל הניתן לפי העומס הצפוי, אם יש אפשרות לדעת מראש.
- לגבי המיני-בחנים, תהיה אפשרות להגשה מאוחרת אבל הם ייפתרו בכיתה מיד עם מועד ההגשה המקורי ואני מצפה ליושרה.