


עיבוד שפה טבעית ש8:

תיוג רצפים נוירוני



(SLP 9)

# רשתות נוירונים פשוטות - תזכורת


- יחידת הבסיס ("נוירון") - פרספטרון (ציון לינארי, חיזוי לפי  $0 <$ )



- נדמיין פרספטרון שצריך לחשב AND




## רשתות נוירונים פשוטות - תזכורת





- יחידת הבסיס ("נוירון") - פרספטרון

- נדמיין פרספטרון שצריך לחשב AND

- ונעת פרספטרון שצריך לחשב OR



# רשתות נוירונים פשוטות - תזכורת




- יחידת הבסיס ("נוירון") - פרספטרון

- נדמיין פרספטרון שצריך לחשב AND

- ונעת פרספטרון שצריך לחשב OR



- מה לגבי XOR?




# רשתות נוירונים פשוטות - תזכורת

- נרכיב שלושה פרספטרונים אחד על-גבי השני

- סתם חיבור לא יעזור (למה?) ולכן נוסיף  
**אקטיבציה** בשכבה האמצעית (השכבה  
הנחבאת, hidden layer)



# רשתות נוירונים בהיזן קדמי (Feedforward NNs, FFN, MLP)




- אותו דבר רק בהמון
  - המון שכבות (= רשתות עמוקות)
  - המון פיצ'רים
  - המון נוירונים חבויים בכל שכבה
- איך מאמנים אותן?
  - פעפוע אחורה - backpropagation
  - איך מאתחלים את המשקלות?
- איזו אקטיבציה בוחרים?
  - ReLU
    - סיגמויד
    - טנגנס היפרבולי tanh
- אילו פיצ'רים מכניסים?

# מגבלות ה-FFN

- התייחסות לכל הקלט בבת אחת
- חישובים שאינם תלויים בסדר הקלט (bag-of-words)
- מוגבל לחיזוי תג אחד (מה נעשה עם תיוג רצפים?)


# רשת נוירונים נשנית (Recurrent Neural Net - RNN)



- נתחיל בדוגמה מקלט בעל נוירון אחד: המצב בתא הכחול נשמר




# רשת נוירונים נשנית (Recurrent Neural Net - RNN)



- נתחיל בדוגמה מקלט בעל נוירון אחד: המצב בתא הכחול נשמר
- ומועבר למצב הבא

# רשת נוירונים נשנית (Recurrent Neural Net - RNN)



- נתחיל בדוגמה מקלט בעל נוירון אחד: המצב בתא הכחול נשמר

- ומועבר למצב הבא

- וכך הלאה

- חשוב: הפרמטרים הם אותם פרמטרים


- צורת ההצגה הזאת נקראת פרישה, גלילה unrolled

# רשת נשנית - פורמלית

- קלטים  $x$  על-פני זמן  $1, \dots, T$
- מצב חבוי  $h$
- קשר ההישנות recurrence relation:
- במקרה שראינו:
  - $h_t = f(x_t, h_{t-1}; \theta)$
  - $\theta = \{\theta_x, \theta_h, b\}; f(x, h) = \theta_x x + \theta_h h + b$
- מקרים יותר סבוכים:
  - קלט שהוא בעצמו וקטור (כמעט תמיד)
  - ואז שכבת הפרמטרים היא...?
  - רשת עם  $f$  שדואג לא "לשכוח" מצבים רחוקים


# מקרי שימוש ברשת נשנית

one to one




(לא רשת  
נשנית)  
סיווג

one to many




כתיבת  
הגדרה  
במילון

many to one




סיווג  
שאינו  
(BoW)

many to many



תרגום,  
תמצות

many to many




תיוג רצפים

(איזו עוד משימה מתחבאת כאן?)


# אימון רשת נשנית

- אלגוריתם העדכון של רשת רגילה - backpropagation: מריצים את הרשת, מחשבים הפסד, מפעפעים לכל הפרמטרים ע"י כלל השרשרת
- ברשת נשנית, נריץ את כל הרשת ונפעפע את כל ההפסדים עבור רצף קלט **בבת אחת**:  
backpropagation through time




# אימון רשת נשנית

- הרבה פעמים נחתוך את ההרצה באמצע ונפעפע בשלבים -  
truncated backpropagation through time



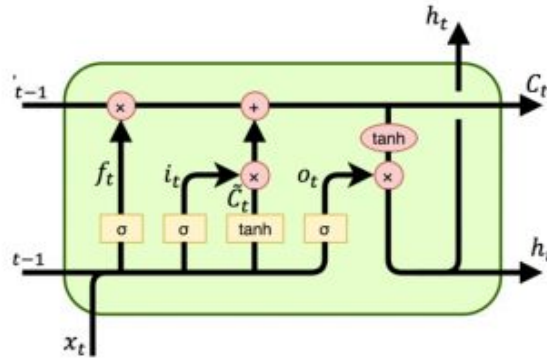
# גרסאות לפונקציית ההישנות

## RNN




מה שראינו עד עכשיו, הכי פשוט  
(ולכן נקרא גם "ונילי" Vanilla RNN)  
(נקרא גם על-שם ההוגה Elman RNN)

## LSTM



מכיל מרכיבים שנועדו לשמור על מצבים  
רחוקים (Long Short-Term Memory)  
הכי נפוץ בשימוש כיום

## GRU



פשרה בין שני הקיצוניים - Gated  
Recurrent Unit שמצליח להסתכל  
אחורה אבל מהיר בהרבה מ-LSTM

# קלט וקטורי


- שיכוני מילים (Word embeddings) - נלמד באריכות עוד שבועיים
- בינתיים נתייחס לזה כאל "קופסה שחורה" - בהינתן מילה, מישהו חישב עבורה וקטור
- הווקטורים "מאוחסנים" בטבלאות
  - יכולים בעצמם להיחשב לפרמטרים של המערכת

$e_6$	$e_5$	$e_4$	$e_3$	$e_2$	$e_1$	
0.64	1.10	0.95	-0.73	-0.33	0.07	שלום
1.33	-0.75	-0.12	0.23	-0.63	0.11	עולם
-0.21	-0.31	0.43	0.11	-0.12	0.27	המונים
-1.50	0.09	1.34	0.92	-1.13	4.03	4563
0.02	0.44	7.01	0.48	0.01	0.55	מד"ב




# רשת נשנית דו-כיוונית (Bidirectional RNN)

- עבור משימות תיוג, הקשר "עתידי" חשוב כמו הקשר "מהעבר"
  - (עברית: אם המילה הבאה היא בבירור מילת יחס, הנוכחית כמעט בוודאות אינה מילת יחס)




- המבנה מבדיל בין הכיוונים - לכל כיוון יש את הפרמטרים שלו  
וה"חיבור" נעשה רק ברמה הבאה

## שכבות ברשת נשנית



- פלט משכבה אחת עולה כקלט לשכבה הבאה
- ברשת חד-כיוונית, אפשר למקבל את העיבוד
- ברשת דו-כיוונית חייבים לחכות לסוף המקטע  
עבור כל שכבה


## מימוש עבור תיוג




## טיזר לנושא הנוירוני הבא-הבא

בשני המקרים האלה  
הפרמטר החבוי ברשת  
הנשנית צריך "לזכור" המון

many to one




many to many



# טיזר לנושא הנוירוני הבא-הבא

- נלמד "לתת תשומת לב" לכל הקלט בשלבי החיזוי או היצירה

- רשתות צומי Attention models



# למימושים - PyTorch

- <https://pytorch.org/>
- תמיכה בהרבה מאוד סוגי רשתות נוירונים (במודול `torch.nn`)
- בניה מודולרית של רשתות, הרצת הסקה (קדימה) ולמידה (אחורה) מובנית
- [הדרכת פייטורץ'](#) עם דוגמת סיווג מסמכים

